

Detecção de Phishing em URLs com Classificadores Clássicos: Um Estudo Comparativo

Vinícius Magalhães Dias¹, João Marcello Machado Braz¹, Pedro Gabryel Araujo do Nascimento¹

¹Disciplina de Reconhecimento de PadrõesPREENCHER: InstituiçãoPREENCHER: Instituição
– [Cidade], [UF] – Brasil

[PREENCHER: emails separados por vírgula]

Abstract. *This paper evaluates seven classical classifiers on the task of phishing URL detection using the UCI Phishing Websites dataset (11.055 samples, 30 categorical attributes). Models were assessed through stratified 10-fold cross-validation and on a held-out test set, using accuracy, macro F1-score, and AUC-ROC as metrics. Random Forest achieved the best results ($F1 = 0,974$, $AUC-ROC = 0,998$). A Friedman statistical test confirmed that performance differences across classifiers are significant ($\chi^2 = 56,27$, $p < 0,001$). Feature importance analysis indicates that SSL certificate status and the proportion of external anchor URLs are the most discriminative attributes.*

Resumo. *Este trabalho avalia sete classificadores clássicos na tarefa de detecção de URLs de phishing usando o dataset UCI Phishing Websites (11.055 amostras, 30 atributos categóricos). Os modelos foram avaliados por validação cruzada estratificada de 10 folds e em conjunto de teste separado, com métricas de acurácia, F1 macro e AUC-ROC. Random Forest obteve o melhor desempenho ($F1 = 0,974$, $AUC-ROC = 0,998$). O teste de Friedman confirmou diferenças estatisticamente significativas entre os classificadores ($\chi^2 = 56,27$, $p < 0,001$). A análise de importância indica que o estado do certificado SSL e a proporção de âncoras externas são os atributos mais discriminativos do conjunto de dados.*

1. Introdução

Phishing é uma técnica de engenharia social na qual o atacante cria URLs fraudulentas que imitam serviços legítimos para roubar credenciais ou induzir a instalação de malware [Verma and Das 2017]. O volume do problema é expressivo: somente em 2023, a Anti-Phishing Working Group registrou cerca de cinco milhões de ataques de phishing, o maior total anual de sua série histórica [Anti-Phishing Working Group 2024]. Nesse cenário, a triagem puramente manual é inviável; filtros automáticos baseados em aprendizado de máquina tornaram-se componentes essenciais de browsers, gateways de e-mail e proxies corporativos. A efetividade desses sistemas depende da escolha adequada do classificador e dos atributos extraídos da URL.

Este trabalho compara sete classificadores clássicos de aprendizado de máquina — Regressão Logística, Naive Bayes Gaussiano, KNN, Árvore de Decisão, Random Forest, SVM com kernel RBF e Gradient Boosting — na tarefa de detecção de phishing em URLs usando o dataset UCI Phishing Websites [Mohammad et al. 2012], com 11.055 amostras e 30 atributos categóricos. A avaliação combina validação cruzada de 10 folds com teste estatístico de Friedman para verificar a significância das diferenças de desempenho.

2. Trabalhos Relacionados

Mohammad et al. [Mohammad et al. 2012] propuseram o dataset UCI Phishing Websites e um sistema de classificação baseado em regras derivadas dos 30 atributos extraídos manualmente de URL, DNS e HTML, reportando acurácia de 92,4% com classificação fuzzy. O dataset tornou-se referência amplamente adotada em pesquisas subsequentes sobre o tema.

Sahingoz et al. [Sahingoz et al. 2019] compararam sete algoritmos de aprendizado de máquina em um conjunto de URLs coletadas em tempo real, usando atributos léxicos e de conteúdo. Random Forest obteve acurácia de 97,98% e foi o melhor modelo no estudo, na mesma faixa da acurácia de 0,974 alcançada pelo Random Forest neste trabalho.

Jain e Gupta [Jain and Gupta 2018] propuseram um classificador baseado em hiperlinks extraídos do lado do cliente, sem acesso ao conteúdo da página, alcançando acurácia de 98,4%. A abordagem é relevante por dispensar o carregamento da página, reduzindo latência na detecção.

Verma e Das [Verma and Das 2017] investigaram extração rápida de atributos léxicos da string da URL para detecção de URLs maliciosas, mostrando que características simples como comprimento, uso de subdomínios e presença de caracteres especiais são altamente discriminativas, mesmo sem análise do conteúdo da página.

3. Fundamentação Teórica

Os sete classificadores avaliados diferem em hipóteses de indução e complexidade computacional. Regressão Logística estima a probabilidade posterior de cada classe como função sigmoide de uma combinação linear dos atributos padronizados, sendo eficiente e interpretável. Naive Bayes Gaussiano assume independência condicional entre atributos e distribuição normal dentro de cada classe; a violação dessas hipóteses em dados categóricos pode degradar significativamente o desempenho [Demšar 2006]. K -Nearest Neighbors ($k = 5$) [Cover and Hart 1967] classifica por maioria de votos dos k vizinhos mais próximos no espaço padronizado, sem fase de treino explícita, mas com custo de predição linear no tamanho do conjunto de treino. Árvore de Decisão particiona recursivamente o espaço de atributos maximizando a redução de impureza de Gini [Breiman et al. 1984], produzindo regras diretamente interpretáveis. Random Forest constrói um ensemble de árvores sobre subconjuntos aleatórios dos dados e dos atributos, reduzindo variância por agregação e fornecendo estimativas naturais de importância de atributos [Breiman 2001]. Máquina de Vetores de Suporte com kernel RBF mapeia os dados para um espaço de maior dimensão e encontra o hiperplano de margem máxima nesse espaço [Cortes and Vapnik 1995]; a padronização dos atributos é essencial para o funcionamento correto do kernel. Gradient Boosting [Friedman 2001] treina uma sequência de árvores rasas de forma aditiva, onde cada árvore corrige os resíduos da anterior, obtendo modelos de alta acurácia ao custo de maior tempo de treino; implementações escaláveis desse paradigma, como o XGBoost [Chen and Guestrin 2016], difundiram seu uso em aplicações de larga escala.

4. Metodologia

4.1. Dataset

O dataset UCI Phishing Websites [Mohammad et al. 2012] contém 11.055 amostras descritas por 30 atributos categóricos de valor ternário $\{-1, 0, 1\}$, extraídos de características da URL, do servidor DNS, do código HTML e do comportamento JavaScript da página. São 6.157 amostras de phishing (55,7%) e 4.898 legítimas, configurando um leve desbalanceamento. Não há valores faltantes. Os rótulos seguem a convenção $+1$ para phishing e -1 para legítimo.

4.2. Configuração Experimental

Os dados foram divididos em treino (80%) e teste (20%) com estratificação por classe e `random_state=42`, garantindo reprodutibilidade. Os hiperparâmetros seguiram os valores padrão da literatura: `n_estimators=200` para Random Forest e Gradient Boosting, $k = 5$ para KNN e `max_iter=2000` para a Regressão Logística. Classificadores sensíveis à escala — Regressão Logística, Naive Bayes, KNN e SVM — receberam os atributos padronizados via `StandardScaler` dentro de um `Pipeline`. Os demais operaram sobre os dados brutos. Toda a implementação — modelos, padronização, validação cruzada e métricas — utilizou a biblioteca `scikit-learn` [Pedregosa et al. 2011].

4.3. Avaliação e Teste Estatístico

A avaliação principal utilizou validação cruzada estratificada de 10 folds no conjunto de treino, coletando acurácia, F1 macro e AUC-ROC por fold. Os modelos foram então treinados em todo o conjunto de treino e avaliados no conjunto de teste. Para determinar se as diferenças de desempenho são estatisticamente significativas, aplicou-se o teste não paramétrico de Friedman [Demšar 2006] sobre os escores de F1 macro por fold, seguido pelo pós-teste de Nemenyi para comparações par a par.

5. Resultados e Discussão

A Tabela 1 apresenta os resultados completos em validação cruzada e no conjunto de teste. Random Forest obteve o melhor desempenho geral, com acurácia de 0,974, $F1 = 0,974$ e $AUC-ROC = 0,998$ no conjunto de teste, e variância reduzida na validação cruzada ($\sigma = 0,004$), indicando estabilidade. Gradient Boosting e Árvore de Decisão apresentaram resultados próximos, enquanto Regressão Logística, KNN e SVM RBF ficaram em um nível intermediário. Naive Bayes registrou desempenho significativamente inferior ao dos demais, com F1 de 0,561, reflexo direto da violação da suposição gaussiana: os atributos do dataset são categóricos ternários, incompatíveis com a hipótese de normalidade do modelo.

As curvas ROC (Figura 1) confirmam o padrão observado na Tabela 1: os seis modelos com melhor F1 apresentam AUC-ROC elevado e próximo do ótimo, indicando forte discriminação em todos os limiares. A curva de Naive Bayes, apesar de AUC-ROC competitivo, colapsa em F1 muito inferior porque a distribuição de probabilidades geradas pelo modelo é mal calibrada: as suposições de independência do Naive Bayes empurram as probabilidades estimadas para os extremos 0 e 1 [Niculescu-Mizil and Caruana 2005], tornando o limiar padrão de 0,5 inadequado.

Tabela 1. Desempenho dos classificadores em validação cruzada de 10 folds (CV) e no conjunto de teste. F1 refere-se à média macro.

Classificador	F1 (CV, $\mu \pm \sigma$)	F1 (teste)	AUC-ROC	Tempo (s)
Regressão Logística	0,926 $\pm$ 0,006	0,927	0,981	0,01
Naive Bayes	0,561 $\pm$ 0,012	0,561	0,970	0,00
KNN (k=5)	0,940 $\pm$ 0,005	0,949	0,987	0,00
Árvore de Decisão	0,961 $\pm$ 0,006	0,971	0,980	0,01
Random Forest	0,970 $\pm$ 0,004	0,974	0,998	0,17
SVM RBF	0,948 $\pm$ 0,006	0,951	0,989	2,14
Gradient Boosting	0,952 $\pm$ 0,005	0,956	0,994	0,75

O teste de Friedman resultou em $\chi^2 = 56,27$ ($p < 0,001$), rejeitando a hipótese nula de desempenho estatisticamente equivalente entre todos os classificadores. O pós-teste de Nemenyi revelou que Naive Bayes difere significativamente de todos os demais modelos ($p < 0,05$), ao passo que as diferenças entre os outros seis classificadores não atingem significância estatística nesse critério, sugerindo que todos são escolhas viáveis para o problema.

A Figura 2 mostra os quinze atributos de maior importância segundo o Random Forest. Os dois mais relevantes — `sslfinal_state` (estado do certificado SSL) e `url_of_anchor` (proporção de âncoras externas) — respondem juntos por 56,7% da importância total, indicando que indicadores de segurança do protocolo e de comportamento de hiperlinks da página concentram a maior parte do poder discriminativo. Os atributos restantes contribuem de forma mais distribuída, sem nenhum outro com importância individual relevante.

6. Conclusão

Este trabalho comparou sete classificadores clássicos na tarefa de detecção de phishing em URLs usando o dataset UCI Phishing Websites (11.055 amostras, 30 atributos). Random Forest apresentou o melhor desempenho (F1 = 0,974, AUC-ROC = 0,998), e o teste de Friedman confirmou diferenças estatisticamente significativas entre os modelos ($\chi^2 = 56,27$, $p < 0,001$). A análise de importância indicou que o estado do certificado SSL e a proporção de âncoras externas são os atributos mais discriminativos. Como limitação, o dataset utiliza atributos extraídos manualmente, o que implica latência adicional na detecção em tempo real; trabalhos futuros poderiam investigar atributos léxicos brutos da URL, dispensando o acesso ao conteúdo da página.

Referências

- Anti-Phishing Working Group (2024). Phishing activity trends report, 4th quarter 2023. Technical report, APWG.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth, Belmont, CA.




Figura 1. Curvas ROC dos sete classificadores avaliados no conjunto de teste.

- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Cover, T. M. and Hart, P. E. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232.
- Jain, A. K. and Gupta, B. B. (2018). Towards detection of phishing websites on client-side using machine learning based approach. *Telecommunication Systems*, 68(4):687–700.
- Mohammad, R. M., Thabtah, F., and McCluskey, L. (2012). An assessment of features related to phishing websites using an automated technique. In *International Conference for Internet Technology and Secured Transactions*, pages 492–497.




Figura 2. Importância (critério Gini) dos 15 atributos mais relevantes segundo o Random Forest.

- Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 625–632.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Sahingoz, O. K., Buber, E., Demir, O., and Diri, B. (2019). Machine learning based phishing detection from URLs. *Expert Systems with Applications*, 117:345–357.
- Verma, R. and Das, A. (2017). What’s in a URL: Fast feature extraction and malicious URL detection. In *Proceedings of the 3rd ACM International Workshop on Security and Privacy Analytics*, pages 55–63.