

Detecção de Phishing em URLs com Classificadores Clássicos

Um Estudo Comparativo

Vinícius M. Dias João M. M. Braz Pedro G. A. do Nascimento

Ciência da Computação — Universidade Estadual do Piauí (UESPI)

Reconhecimento de Padrões

- ① Introdução e Trabalhos Relacionados
- ② Fundamentação e Metodologia
- ③ Resultados e Conclusão

Introdução e Trabalhos Relacionados

O problema: phishing

- Phishing é engenharia social: URLs fraudulentas imitam serviços legítimos para roubar credenciais ou instalar malware.
- **Escala do problema:** só em 2023, a APWG registrou cerca de **cinco milhões** de ataques — o maior total anual já registrado.
- Triagem manual é inviável $\Rightarrow$ filtros automáticos com **aprendizado de máquina** tornaram-se essenciais em browsers, e-mail e proxies.

Pergunta do trabalho

Qual classificador clássico é mais eficaz para detectar phishing em URLs, e a diferença entre eles é estatisticamente significativa?

O que este trabalho faz

- Compara **sete classificadores clássicos**:
 - Regressão Logística, Naive Bayes, KNN, Árvore de Decisão,
 - Random Forest, SVM (kernel RBF), Gradient Boosting.
- Base: **UCI Phishing Websites** — 11.055 amostras, 30 atributos.
- Avaliação com validação cruzada de 10 folds e teste estatístico de Friedman.

- **Mohammad et al. (2012)** — propuseram o dataset UCI, definindo e extraíndo automaticamente os 30 atributos.
- **Sahingoz et al. (2019)** — compararam sete algoritmos; Random Forest venceu (97,98% de acurácia), na mesma faixa do nosso resultado.
- **Jain e Gupta (2018)** — classificação por hiperlinks do lado do cliente (98,4%), sem carregar a página.
- **Verma e Das (2017)** — atributos léxicos da string da URL já são altamente discriminativos.

Fundamentação e Metodologia

Os sete classificadores


Modelo	Ideia central
Regressão Logística	Fronteira linear; probabilidade sigmoidal
Naive Bayes Gaussiano	Assume independência e normalidade
KNN ($k = 5$)	Vota nos vizinhos mais próximos
Árvore de Decisão	Partições por impureza de Gini
Random Forest	Ensemble de árvores (reduz variância)
SVM (kernel RBF)	Margem máxima em espaço transformado
Gradient Boosting	Árvores aditivas que corrigem resíduos

Modelos sensíveis à escala (RegLog, NB, KNN, SVM) recebem padronização; os baseados em árvore, não.

O dataset

- **UCI Phishing Websites:** 11.055 amostras, 30 atributos categóricos discretos.
- Maioria **binários** $\{-1, 1\}$ (ausência/presença); alguns **ternários** $\{-1, 0, 1\}$ (intensidade).
- 6.157 phishing (55,7%) e 4.898 legítimas — leve desbalanceamento, sem valores faltantes.
- Atributos extraídos de URL, DNS, HTML e JavaScript.

Pipeline experimental



Como medimos e comparamos

- **Protocolo:** 80/20 estratificado, `random_state=42` (reprodutível); validação cruzada de 10 folds no treino.
- **Métricas:** acurácia, F1 macro e AUC-ROC.
- **Teste estatístico:** Friedman (as diferenças são reais?) + pós-teste de Nemenyi (quais modelos diferem?).
- **Ferramentas:** scikit-learn, SciPy, scikit-posthocs.

Por que teste estatístico?

Diferenças pequenas de F1 podem ser ruído. O Friedman diz se há diferença *significativa*, não apenas numérica.

Resultados e Conclusão

Resultados: desempenho dos modelos

Classificador	F1 (CV)	F1 (teste)	AUC-ROC	Tempo (s)
Regressão Logística	0,926	0,927	0,981	0,01
Naive Bayes	0,561	0,561	0,970	0,00
KNN ($k = 5$)	0,940	0,949	0,987	0,00
Árvore de Decisão	0,961	0,971	0,980	0,01
Random Forest	0,970	0,974	0,998	0,17
SVM RBF	0,948	0,951	0,989	2,14
Gradient Boosting	0,952	0,956	0,994	0,75

Random Forest vence: $F1 = 0,974$, $AUC-ROC = 0,998$, com baixa variância e treino em fração de segundo.

Naive Bayes despenca

- $F1 = 0,561$ (muito abaixo).
- AUC-ROC até competitivo (0,970), mas probabilidades mal calibradas $\Rightarrow$ limiar 0,5 falha.
- Atributos discretos violam a hipótese gaussiana.

Árvore de Decisão

- 2º melhor F1 (0,971)...
- ... mas o *menor* AUC dos bons (0,980).
- Decide bem no limiar padrão, mas gradua mal as probabilidades.

- **Friedman:** $\chi^2 = 56,27$ ($p < 0,001$) — as diferenças são significativas.
- **Nemenyi:** só o Naive Bayes difere dos demais; os outros seis são estatisticamente equivalentes — todos viáveis.
- **Atributos mais discriminativos:** `sslfinal_state` (SSL) e `url_of_anchor` (âncoras externas) somam 56,7% da importância.

No artigo: Figura 2 (curvas ROC) e Figura 3 (importância dos atributos) detalham estes pontos.

Conclusão

- Random Forest foi o melhor: $F1 = 0,974$, $AUC-ROC = 0,998$, rápido e estável.
- As diferenças entre os modelos são estatisticamente significativas (Friedman); o Naive Bayes é o destoante.
- SSL e proporção de âncoras externas concentram o poder discriminativo.

Limitação e trabalhos futuros

Os atributos são extraídos manualmente (implica latência). Próximo passo: atributos léxicos brutos da URL, sem carregar a página.

Obrigado!

Perguntas?

Vinícius M. Dias • João M. M. Braz • Pedro G. A. do Nascimento
UESPI — Reconhecimento de Padrões